商业炒作还是货真价实?

——足球运动员身价分析

目录

什么是五大联赛

如何研究球员身价

球星的特征

球员身价影响因素分析

模型的具体运用

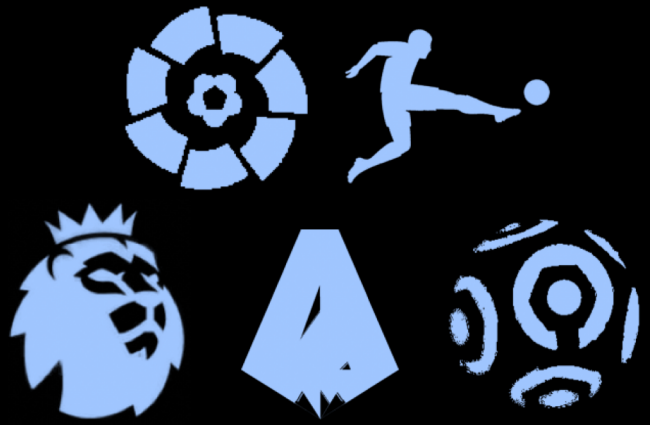

什么是五大联赛？

- 五大联赛是全球水平最高、商业开发最成功的五个足球联赛总称

- 2018至1019赛季，五大联赛收入总和约为235亿英镑，折合2140亿人民币

- 五大联赛几乎囊括了全球最优秀的足球运动员，代表足球运动领域的最高水平

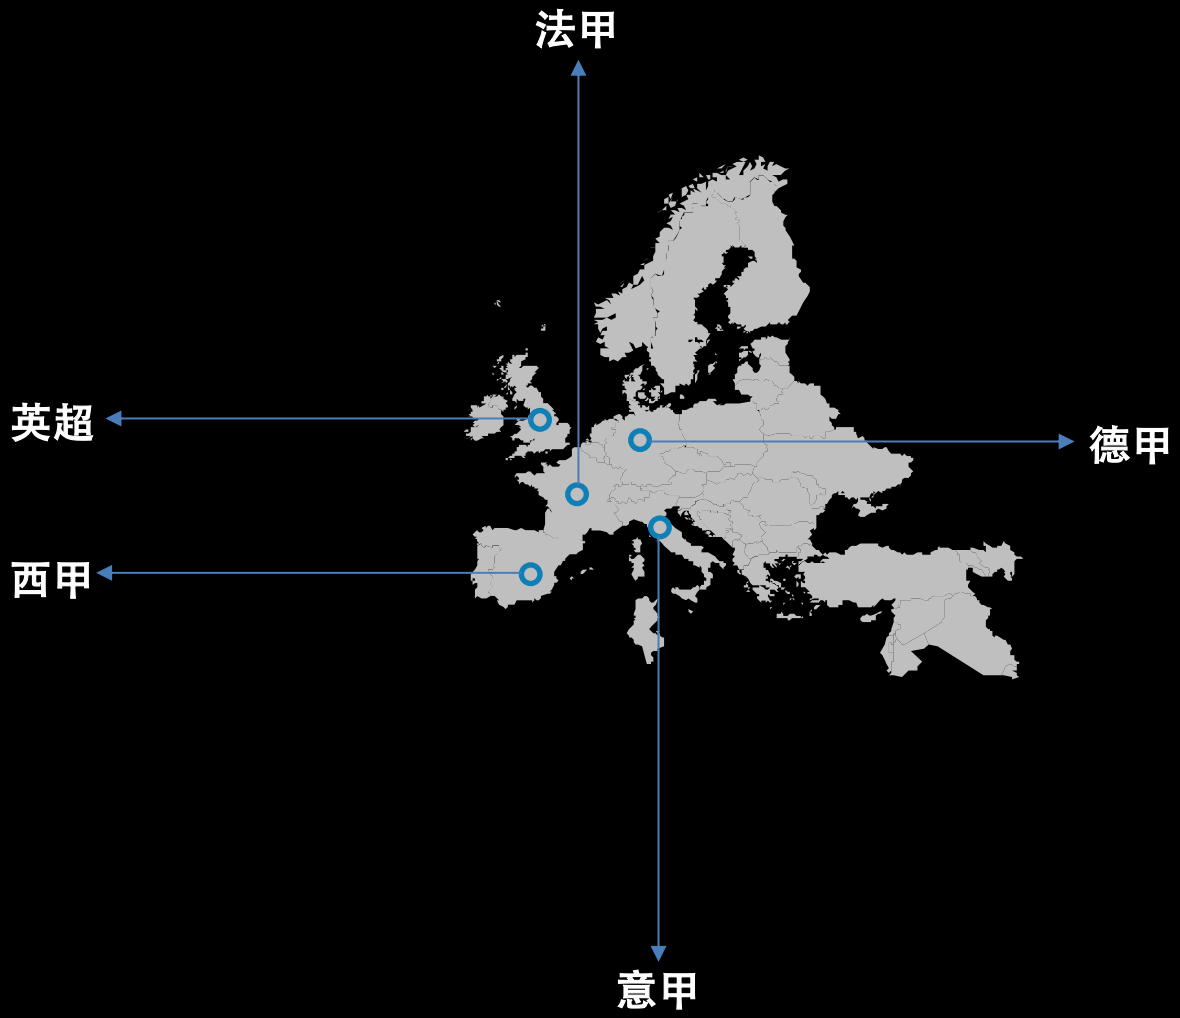

- 近年来，由于资本的大量注入，球员交易愈发频发，球员身价极速上涨
- 球员身价的上涨给各俱乐部的引援工作带来巨大的不确定性
- 能否引入性价比最高的球员是俱乐部一个赛季成败的关键

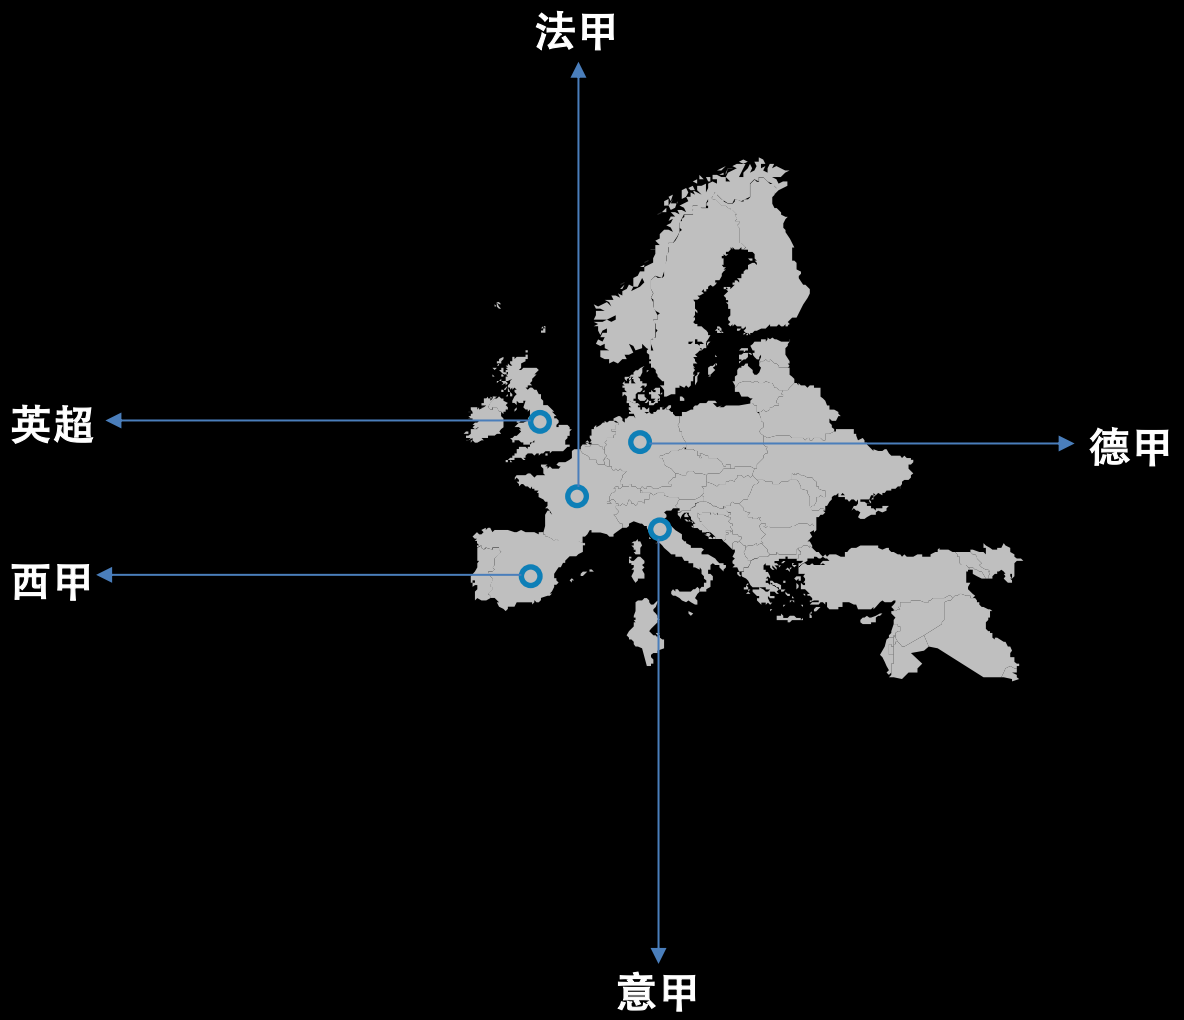

如何研究球员身价？

数据说明

因变量与球员基本信息

变量类型		变量名	详细说明	取值范围	备注
因变量		球员身价	连续变量	[10,20000]	单位：万欧元
自变量	球员基本信息	球员姓名	类别变量	1743个水平	共1743名球员
		球员身高	连续变量	[162,201]	单位：厘米
		球员年龄	连续变量	[14,42]	单位：岁
		国籍	类别变量	91个水平	球员来自91个不同国家
		所在俱乐部	类别变量	98个水平	五大联赛一共98支俱乐部
		所属联赛	类别变量	5个水平	英超，西甲，德甲，意甲，法甲
		位置	类别变量	4个水平	前锋，中场，后卫，门将
		额外位置数量	离散变量	0,1,2	
		惯用脚	类别变量	3个水平	左脚，右脚，双脚

数据说明

球员比赛数据

变量类型		变量名	详细说明	取值范围	备注
自变量	球员比赛数据	出场时间	连续变量	[27, 1530]	单位：分钟
		进球个数	离散变量	0到17	整数
		助攻次数	离散变量	0到11	整数
		场均射门	连续变量	[0, 5.7]	单位：次
		场均射正	连续变量	[0, 2.4]	单位：次
		场均过人	连续变量	[0, 5.1]	单位：次
		场均被侵犯	连续变量	[0, 4.7]	单位：次
		场均越位	连续变量	[0, 1.6]	单位：次
		场均失误	连续变量	[0, 4.9]	单位：次

数据说明

球员比赛数据

变量类型		变量名	详细说明	取值范围	备注
自变量	球员比赛数据	场均关键传球	连续变量	[0, 4.0]	单位：次
		场均被抢断	连续变量	[0, 4.3]	单位：次
		场均传球	连续变量	[2.0, 88.8]	单位：次
		场均传球成功率	连续变量	[0, 1]	
		场均前场传球成功率	连续变量	[0, 1]	
		场均传中	连续变量	[0, 3.0]	单位：次
		场均长传	连续变量	[0, 13.5]	单位：次
		场均直塞	连续变量	[0, 0.6]	单位：次
		场均抢断	连续变量	[0, 4.6]	单位：次

数据说明

球员比赛数据

变量类型		变量名	详细说明	取值范围	备注
自变量	球员比赛数据	场均拦截	连续变量	[0, 4.2]	单位：次
		场均解围	连续变量	[0, 7.6]	单位：次
		场均封堵	连续变量	[0, 2.2]	单位：次
		场均造越位	连续变量	[0, 1.6]	单位：次
		场均犯规	连续变量	[0, 3.0]	单位：次
		场均被过	连续变量	[0, 3.0]	单位：次
		致命失误次数	离散变量	0到4	整数
		场均评分	连续变量	[5.87, 8.75]	满分10分

球员身价

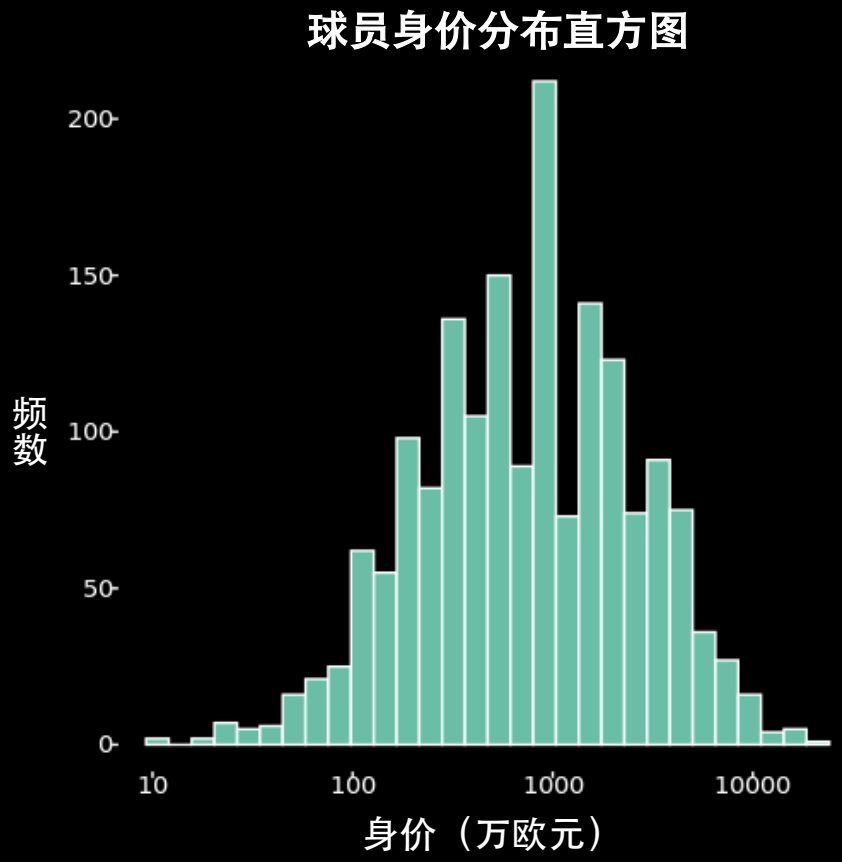

- 右偏分布，中位数仅为800万欧元
- 高身价球员稀少，5000万欧元以上球员仅有89人
- 身价差异巨大，最高身价2亿欧元，最低身价仅10万欧元

惯用脚与身价

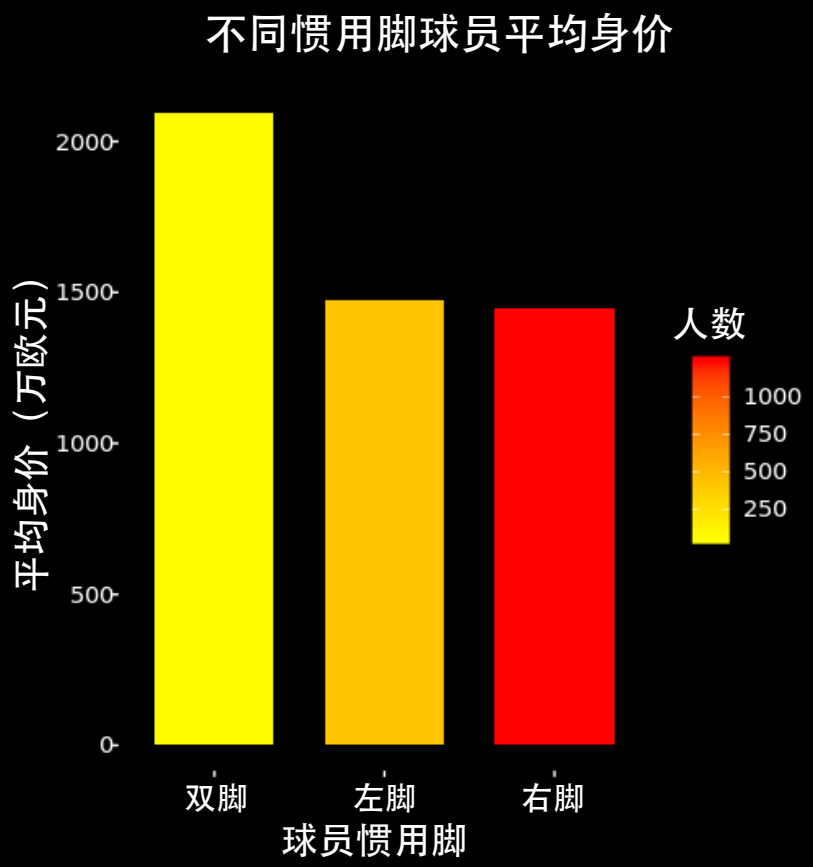

- 惯用脚为右脚的球员最多，双脚均衡的球员较少
- 左右脚球员身价差不不大，但双脚均衡的球员更吃香

球员位置与身价

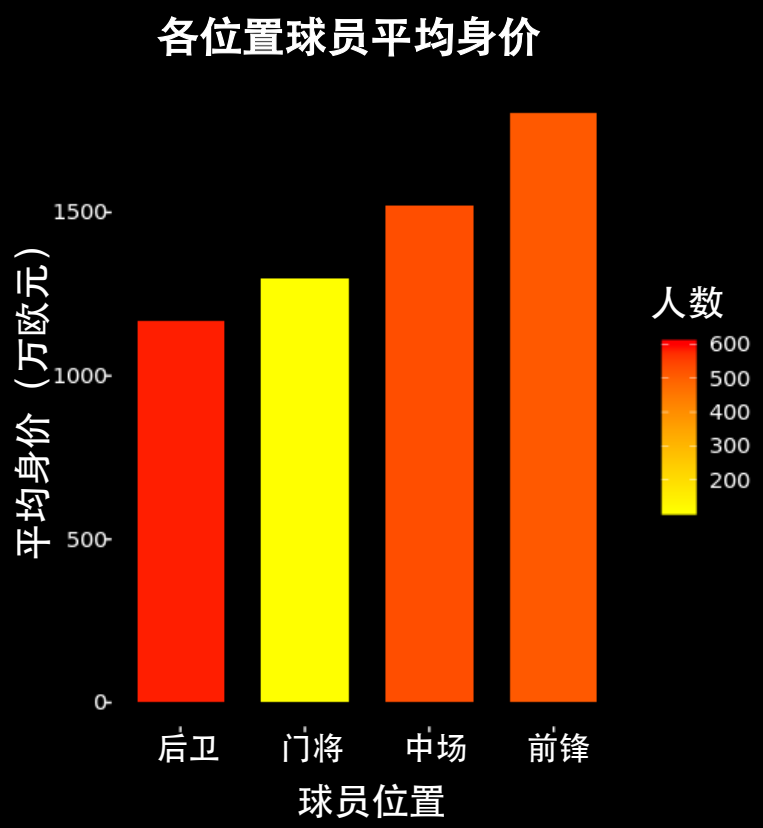

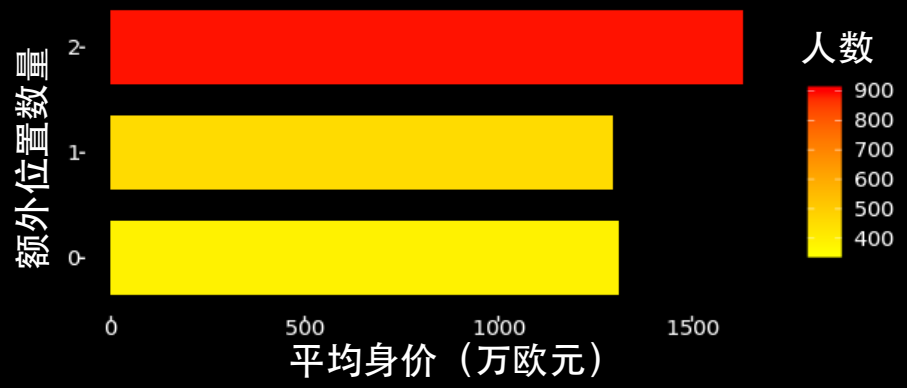

- 中前场球员身价大于后场球员身价，最高平均身价为前锋位置
- 绝大部分球员不局限与某个固定位置，相应身价也更高

联赛与身价

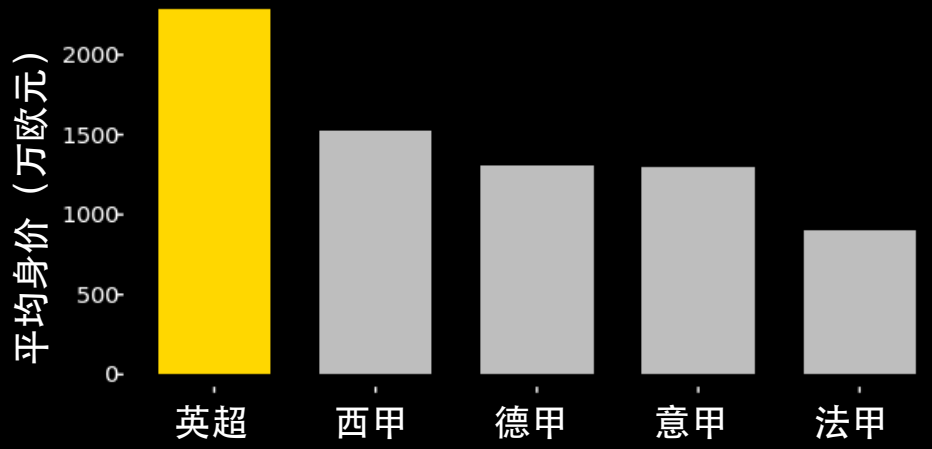

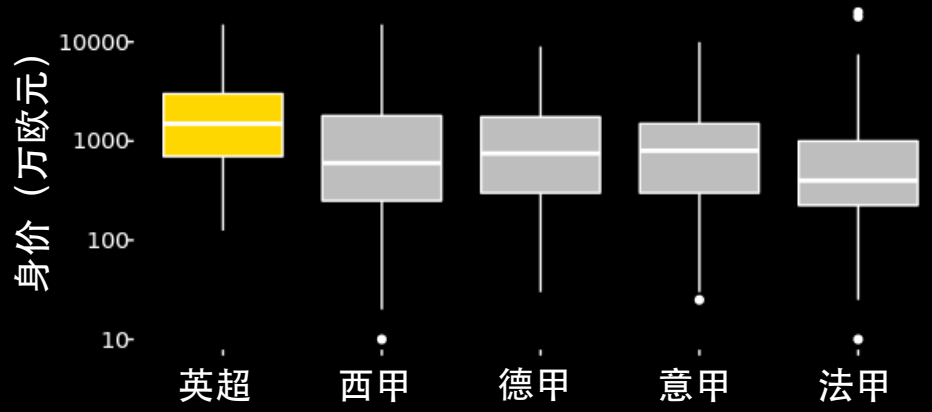

- 英超联赛是名副其实的“印钞”联赛，球员平均身价大于其他联赛
- 法甲联赛球员平均身价最低，仅为907万欧元，不足英超联赛一半
- 其余三大联赛球员平均身价接近，但均不到英超联赛75%

年龄与身价

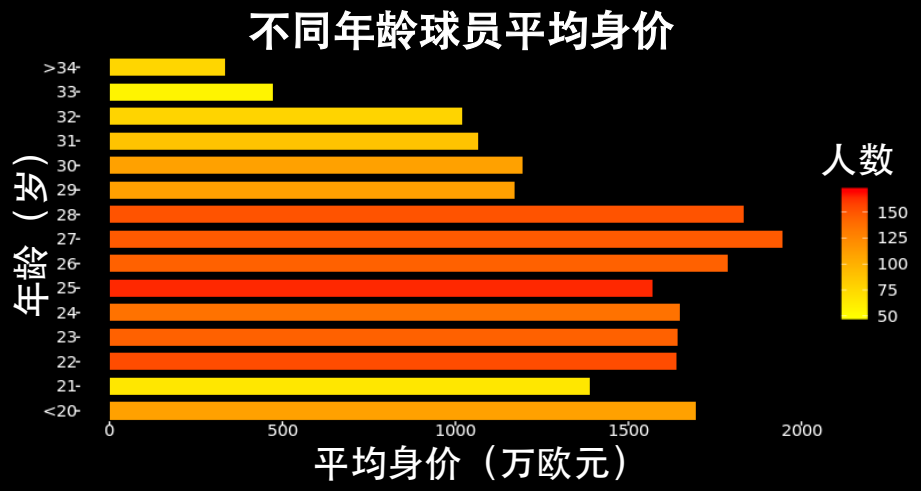

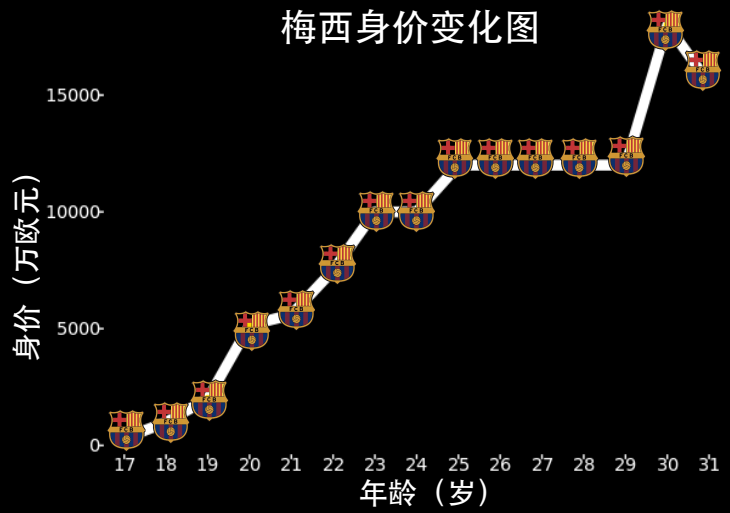

- 职业球员年龄集中在22岁到28岁
- 27岁是职业球员身价顶峰，之后会随年龄增长而逐渐降低

俱乐部排名与身价

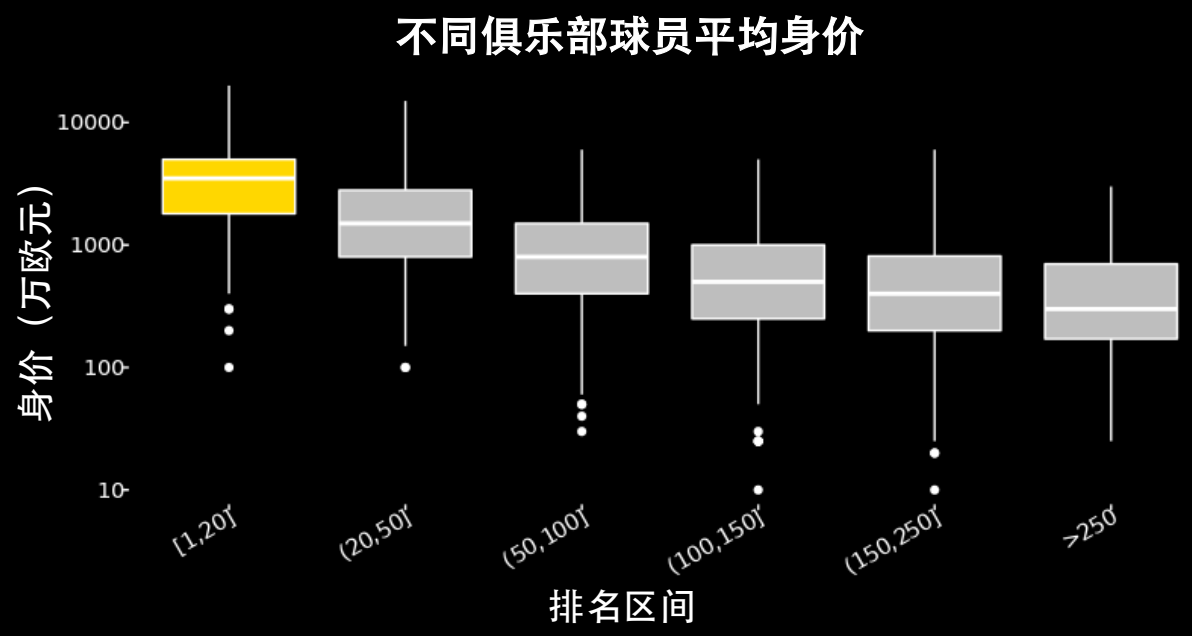

⚽ 球员所在俱乐部越强，球员身价普遍更高

球员国籍与身价

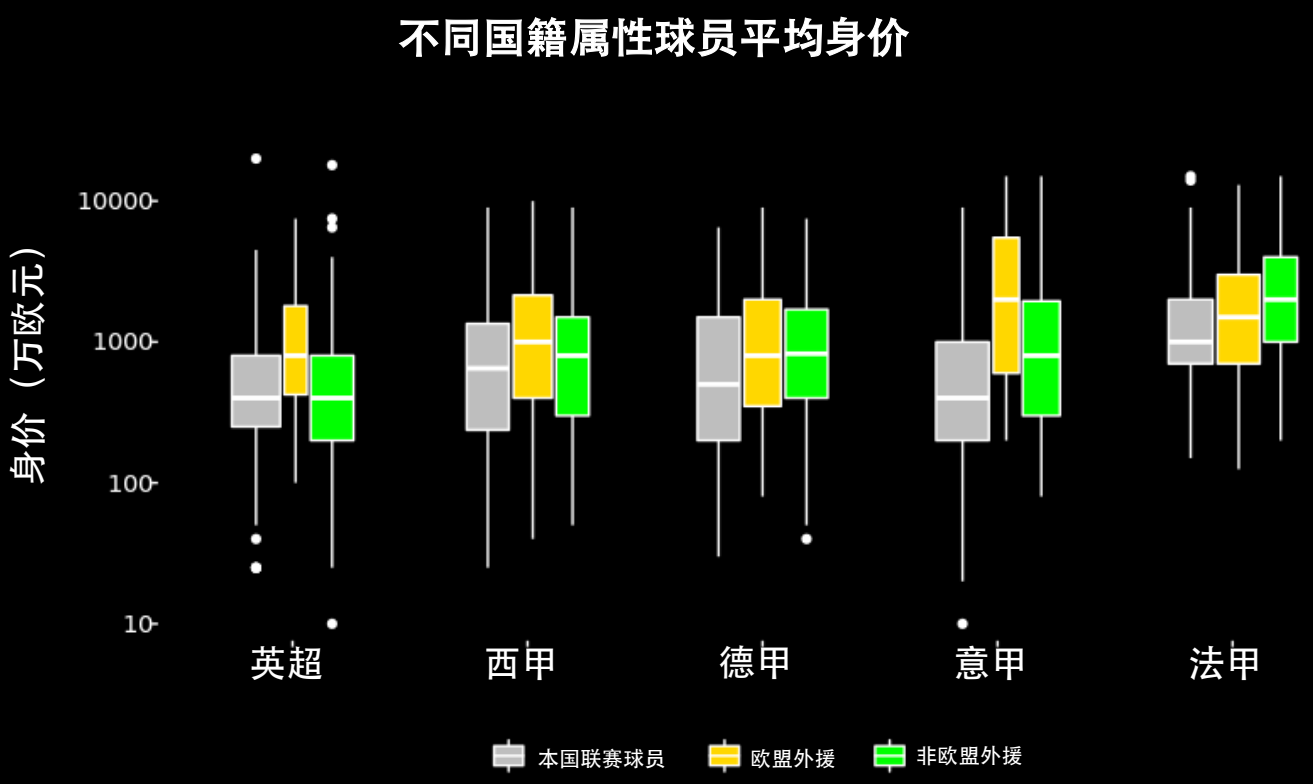

- 各大联赛中的外援平均身价高于本国联赛球员平均身价
- 除法甲外，欧盟外援整体身价略高于非欧盟外援身价

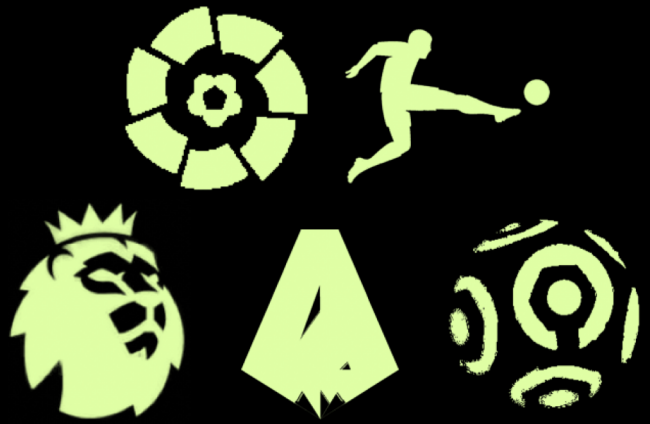

球星的特征

决策树模型

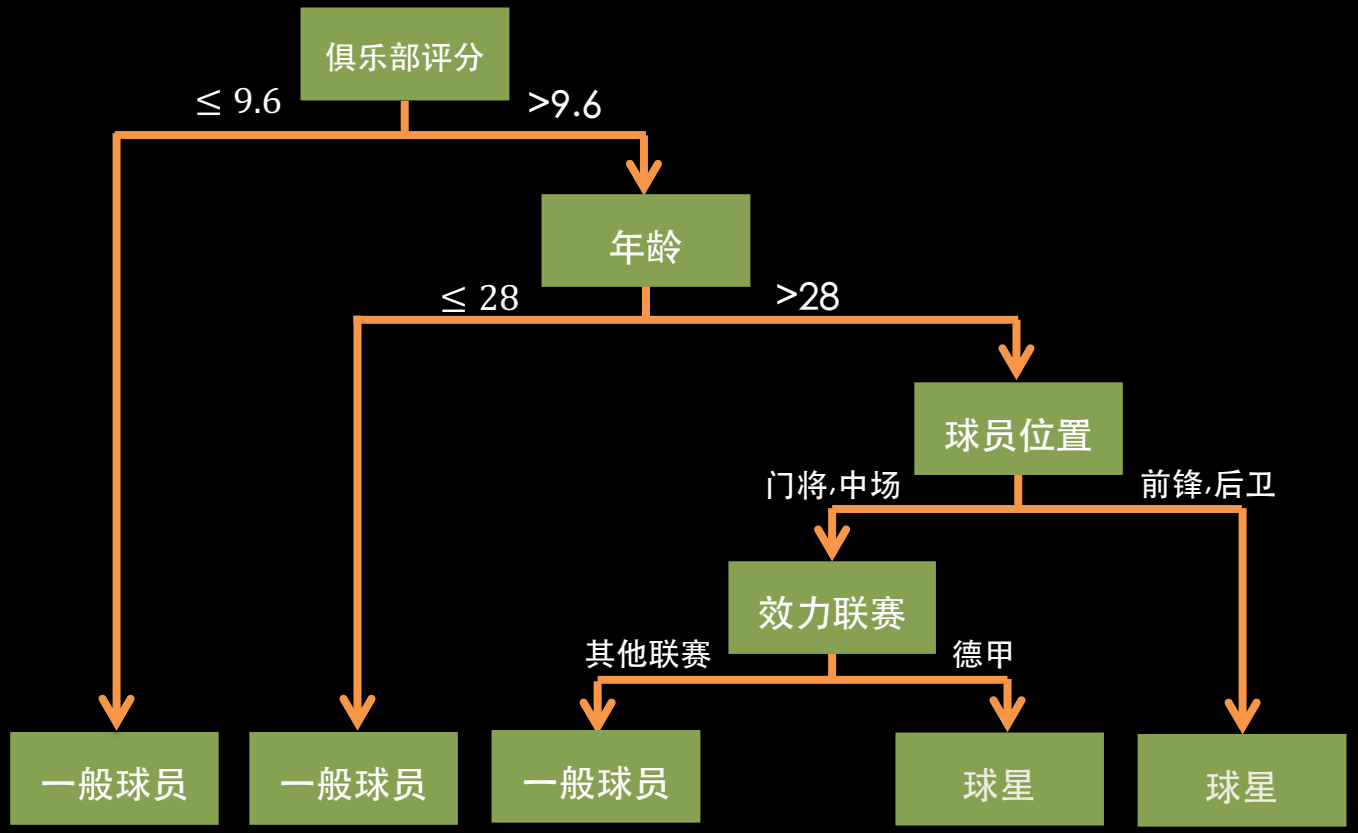
俱乐部评分
≤ 9.6
>9.6
年龄
≤ 28
>28
球员位置
门将,中场
前锋,后卫
效力联赛
其他联赛
德甲
一般球员
一般球员
一般球员
球星
球星

模型对比

决策树

真实值 \ 预测值	一般球员	球星
一般球员	372	113
球星	2	35

AUC=0.8915

随机森林

真实值 \ 预测值	一般球员	球星
一般球员	477	8
球星	28	9

AUC=0.6134

XGBoost

真实值 \ 预测值	一般球员	球星
一般球员	424	61
球星	5	32

AUC=0.9034

球员身价影响因素分析

线性回归模型

建模方法

- 比赛数据为高维数据，且相关性较强，用PCA做降维处理
- 年龄变量处理 $(\text{年龄} - 27)^2$
- 对类别变量任意选择一个基准组
- 使用AIC对模型进行变量选择，选取AIC最小的模型

线性模型参数估计表

自变量		参数估计值	p值	显著水平	备注
所属联赛	法甲	-0.53	0.00	⚽⚽⚽	基准组为“英超”
	德甲	-0.67	0.00	⚽⚽⚽	
	意甲	-0.41	0.00	⚽⚽⚽	
	西甲	-0.76	0.00	⚽⚽⚽	
场上位置	前锋	0.38	0.00	⚽⚽⚽	基准组为“中场”
	门将	3.88	0.00	⚽⚽⚽	
	后卫	0.22	0.00	⚽⚽⚽	
球员类型	欧盟外援	0.22	0.00	⚽⚽⚽	基准组为“本国联赛球员”
	非欧盟外援	0.08	0.10		
年龄	$(\text{年龄} - 27)^2$	-0.02	0.00	⚽⚽⚽	
	球队排名	2.51	0.00	⚽⚽⚽	
	PCA	0.48	0.00	⚽⚽⚽	
F检验	p值 < 0.01		$R^2 = 0.52$		

模型对比

采用十折交叉验证的方法分别训练线性回归模型，随机森林模型和XGBoost模型，并计算模型均方误差的均值

	模型		
	线性回归	随机森林	XGBoost
MSE	2857924	1886284	2293841
预测准确率	48.88%	47.33%	47.05%

（预测准确率=预测值大于0.5倍真实值，小于1.5倍真实值的人数/总人数）

模型的具体运用

上海某中超俱乐部准备从欧洲五大联赛中引进一名强力的前锋，经过初步筛选，确定了个名潜在的目标，三名外援比赛数据如下表所示：

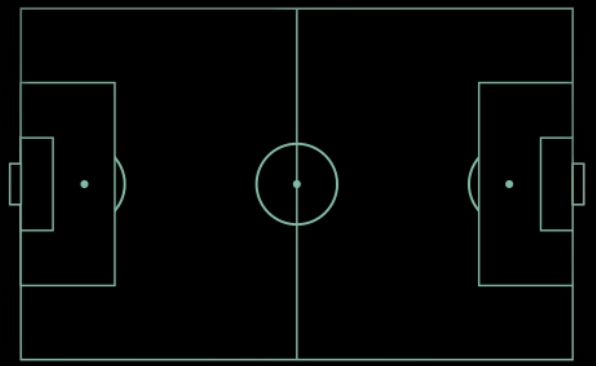

姓名	年龄	惯用脚	效力联赛	场上位置	球队排名	比赛数据	身价（万欧元）
A	28	双脚	西甲	前锋	11	…	15000
B	28	右脚	西甲	前锋	3	…	13000
C	27	右脚	英超	前锋	1	…	12000

通过模型预测，得到的结果为:

姓名	身价	模型预测身价	比值
A	15000	2524	5.94
B	13000	4708	2.76
C	12000	17938	0.67

（比值 = 身价/模型预测身价）

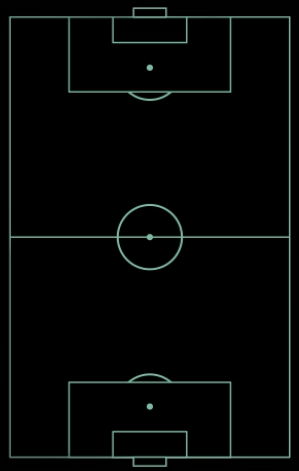

模型的缺点与改进

- 球员的商业价值无法用数据进行量化
- 球员位置需要更精确的分类
- 年轻球员的潜力需要量化（年龄因素需要更精确的处理）

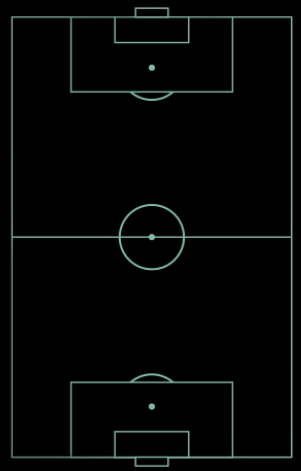

Thanks